# ANNEXE GÉNIE CIVIL

## 1. Données générales du chantier

Ces données constituent la base de votre analyse de risques et de la construction du dataset.

| Paramètre | Valeur / Observation |
|---|---|
| Type d'ouvrage | Immeuble R+6 (4 niveaux résidentiels + 2 niveaux commerciaux) |
| Surface par niveau | 450 m² |
| Surface totale | 2 700 m² |
| Durée prévue des travaux | 15 mois |
| Voisinage | Bâtiments existants à moins de 3 m — risque de nuisances / effondrement |
| Accès chantier | Étroit, circulation difficile — risque de collision engins/piétons |
| Engins de levage | Grue à tour — opérations de levage avec charges variables |

## 2. Données de levage — Grue à tour

Utiliser ces données pour évaluer les risques liés aux opérations de levage (renversement, chute de charge, dépassement de capacité).

| Charge transportée | Benne | Coffrage métallique | Cage de briques | Poutre façonnée |
|---|---|---|---|---|
| Poids (T) | 1,5 | 0,6 | 1,2 | 1,0 |
| Hauteur de la charge (m) | 1,5 | 3,0 | 1,4 | 1,0 |
| Hauteur des élingues (m) | 1,8 | 1,3 | 1,8 | 2,8 |

Le choix d'une grue pour un chantier n'est jamais le fruit du hasard. Il faut pour cela réunir pleins d'informations sur des distances, poids, hauteurs.

Avant d'installer la grue, on doit déterminer Hsc qui est déterminée par la formule suivante : **Hsc= H1+H2+H3** avec

**H1: la plus grande hauteur du bâtiment à construire** **H2: la hauteur de sécurité réglementaire fixée à 2 m**

**H3 : sup de( hauteur de la charge transportée + longueur de ses élingues de levage)**

## 3. Données géotechniques et environnementales

| Paramètre géotechnique | Valeur + implication pour l'analyse |
|---|---|
| Nature du sol | Meuble — risques de glissement, affaissement, tassement |
| Nappe phréatique | 2,2 m de profondeur (fluctuations possibles) — risque d'inondation de fouilles |
| Conditions météo à surveiller | Température, Vent, Pluie — intégrer dans la colonne Description_Environnement |

## 4. Organisation du chantier

| Paramètre | Valeur / Implication |
|---|---|
| Nombre d'ouvriers | 26 |
| Expérience moyenne | 2,5 ans — personnel relativement peu expérimenté |
| Taux formation sécurité | 55 % — 45 % des ouvriers non formés à la sécurité |

## 5. Travail demandé

1. **Présentation à l'équipe Info:** Lire attentivement le dataset et présenter à vos partenaires Info la signification de chaque variable, les abréviations utilisées et les plages de valeurs normales. Cette étape conditionne la qualité du prétraitement.
2. **Construction des descriptions textuelles :** Rédiger les descriptions de la colonne Description_Environnement à partir des données de l'annexe (conditions météo, état des EPI, observations terrain). Varier les formulations pour rendre le dataset représentatif.
3. **Annotation du Score_Risque :** Attribuer un Score_Risque (Faible / Moyen / Élevé / Critique) à chaque ligne du dataset en vous appuyant sur la grille d'analyse. Justifier votre annotation dans la Note Technique.
4. **Estimation probabilité et gravité :** Pour chaque risque identifié, estimer la probabilité d'occurrence (1–4) et la gravité des conséquences (1–4) selon la grille de l'annexe.
5. **Calcul de la criticité:** Criticité = Probabilité × Gravité. Classer: Faible (1–4), Moyen (5–9), Élevé (10–14), Critique (15–16).
6. **Hiérarchisation des 5 risques critiques:** Identifier les 5 risques les plus critiques, les classer par ordre décroissant de criticité et justifier les choix.
7. **Mesures préventives et correctives:** Proposer des mesures préventives (avant l'accident) et correctives pour chaque risque, en tenant compte des contraintes du chantier réel.
8. **Installations sanitaires :** Présenter les installations sanitaires, conditions d'hygiène et installations d'accueil requises selon la réglementation (voir barème section 6).
9. **Validation terrain:** Après réception du fichier de prédictions .csv de l'équipe Info, remplir la colonne Validation_Terrain (Conforme / Non-conforme) en justifiant physiquement chaque cas.

## 6. Barème réglementaire — Installations sanitaires et d'accueil

Référence : Code du travail, Articles R4228-1 à R4228-19 (et CRAM / INRS pour les chantiers).

| Installation | Règle réglementaire |
|---|---|
| WC / Toilettes | 1 cabinet pour 25 ouvriers |
| Urinoirs | 1 urinoir pour 20 ouvriers |
| Lavabos | 1 lavabo pour 10 ouvriers |
| Vestiaires | 1,25 m² / ouvrier (min. 6 m²) |
| Réfectoire / salle repas | Min. 1,25 m² / utilisateur simultané |
| Douches | 1 douche pour 8 ouvriers (travaux sal.) |

| | |
|---|---|
| Eau potable | 3 L / ouvrier / poste minimum |
| Trousse de premiers secours | Obligatoire, accessible en permanence |
| Secouriste | Obligatoire pour chaque chantier occupant 20 personnes au moin 15 jours |

## 7. Lexique de danger — à compléter par l'équipe GC

*Ce lexique sera transmis à l'équipe Info pour calibrer le prétraitement NLP. Compléter en fonction des données réelles du chantier observées.*

| Mot-clé / Expression | Variable concernée | Seuil de déclenchement | Niveau de risque associé |
|---|---|---|---|
| rafales / vent fort | Vent (km/h) | Vent > 45 km/h (grutage interdit) | Élevé / Critique |
| harnais déchiré / endommagé | EPI_Manquants | Toute mention → alerte | Critique |
| sol gelé / verglas | Température (°C) | T < 0 °C + humidité | Moyen / Élevé |
| nappe / inondation / eau | Sol + météo | Présence eau dans fouilles | Élevé |
| échafaudage instable | Type_Travaux | Toute mention → alerte | Critique |
| visibilité réduite / brouillard | Météo | Visibilité < 50 m | Moyen |
| surcharge / charge dépasse | Grue / levage | Dépassement capacité nominale | Critique |
| À compléter… | … | … | … |
| À compléter… | … | … | … |
| À compléter… | … | … | … |

## 8. Grille d'analyse des risques — à remplir

### Échelle de cotation

| Valeur | Probabilité (P) | Gravité (G) | Criticité (P×G) | Niveau |
|---|---|---|---|---|
| 1 | Très improbable | Sans blessure | 1–4 | FAIBLE (F) |
| 2 | Peu probable | Blessure légère | 5–9 | MOYEN (M) |
| 3 | Probable | Blessure grave | 10–14 | ÉLEVÉ (É) |
| 4 | Très probable | Décès / invalidité | 15–16 | CRITIQUE (C) |

- **Situation dangereuse: salarié en présence d'un danger**

**Tableau de la grille (à remplir)**

| ***Opération*** | | ***Composantes du risque*** | | | | | | | ***Mesures de prévention*** |
|---|---|---|---|---|---|---|---|---|---|
| N° | Identification | Danger | Situation dangereuse | P (1–4) | G (1–4) | C (P × G) | Niveau (F/M/É/C) | Dommage | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |
| | | | | | | | | | |

*Note : Utiliser les données numériques ET textuelles du dataset pour remplir cette grille. Pour la colonne "Situation dangereuse", citer la ligne du dataset correspondante (ex : ligne 12, "vent = 68 km/h, Description : rafales violentes en hauteur").*

## ANNEXE INFORMATIQUE / IA

### 1. Description du dataset

Le dataset est fourni avec la documentation. Il contient des données structurées (variables numériques) et une colonne textuelle (Description_Environnement).

- L'équipe Info est chargée de le prétraiter et de l'exploiter en modélisation;
- L'équipe GC est chargée de le lire, de l'interpréter métier et de valider les prédictions intelligentes.

### 2. Missions détaillées

#### 2.1 Prétraitement des données

- Données numériques : gérer les NaN, détecter et traiter les outliers, normaliser/standardiser.
- Données textuelles : nettoyer le texte (lowercase, suppression ponctuation, stop-words), extraire les variables numériques cachées avec Regex (ex : r"vent\s+(\d+)" pour extraire la valeur numérique du vent cité dans le texte), puis appliquer SpaCy ou un Transformer pour l'embedding.
- Intégrer les mots-clés du lexique GC comme features binaires (ex : colonne "alerte_vent" = 1 si "rafales" ou "vent fort" dans la description).
- Sélectionner les variables pertinentes : corrélation, feature importance, VIF pour la multicolinéarité.

#### 2.2 Stratégies de modélisation

Choisir au moins une des deux approches suivantes :

- **Approche A — Embeddings (recommandée) :**
  Utiliser BERT, RoBERTa ou CamemBERT pour transformer chaque Rapport_Inspection en un vecteur sémantique de dimension 768. Concaténer avec les features numériques puis entraîner un classifieur (MLP, RandomForest, XGBoost) pour prédire Score_Risque. Avantage : capture "vent violent" ≈ "rafales" grâce à la sémantique.
- **Approche B — Dual-stream (bonus) :**
  Flux A : réseau ML classique sur les features numériques. Flux B : LSTM ou Transformer sur la séquence textuelle. Fusion: concaténation des sorties des deux flux avant la couche de classification finale.

#### 2.3 Explicabilité augmentée

- Le modèle doit identifier ET surligner dans le texte la raison exacte de l'alerte. Méthodes recommandées : LIME (Local Interpretable Model-agnostic Explanations) ou SHAP (SHapley Additive exPlanations) pour les features numériques ; attention weights pour les approches Transformer.
- Exemple de sortie attendue : "Score_Risque = Critique — Facteurs : Vent = 72 km/h [seuil GC : 45], EPI_Manquants = 3, texte : 'harnais endommagé' (token critique)".

#### 2.4 Évaluation du modèle

- Métriques de classification: Accuracy, Précision, Rappel, F1-score (macro et pondéré), Matrice de confusion, AUC-ROC (one-vs-rest pour les 4 classes).
- Analyse de l'importance des variables : feature importance (RF/XGBoost) ou coefficients (régression logistique).

- Validation croisée : k-fold (k=5 minimum) pour évaluer la robustesse.
- Comparer au moins 2 modèles (ex : Random Forest vs XGBoost vs modèle avec embeddings).

### 3. Structure attendue du Notebook Python

Le notebook doit être structuré en sections claires et reproductibles :

| Section | Titre | Contenu attendu |
|---|---|---|
| Section 0 | Setup & Imports | Imports, seed aléatoire fixée (random_state=42), version des librairies |
| Section 1 | Chargement & inspection des données | df.head(), df.info(), df.describe(), distribution de Score_Risque |
| Section 2 | Prétraitement numérique | NaN, outliers, normalisation, visualisations (histogrammes, boxplots) |
| Section 3 | Prétraitement textuel & NLP | Nettoyage texte, extraction Regex, embedding ou TF-IDF |
| Section 4 | Feature engineering | Features binaires lexique GC, corrélations, sélection de variables |
| Section 5 | Entraînement des modèles | Train/test split (80/20), k-fold, entraînement, sauvegarde modèle |
| Section 6 | Évaluation & métriques | Matrices de confusion, F1, AUC-ROC, comparaison des modèles |
| Section 7 | Explicabilité augmentée | SHAP plots, LIME, attention weights, exemples de prédictions annotées |
| Section 8 | Export des prédictions | Génération du fichier predictions.csv sur le jeu de test |
| Section 9 | Interprétation & conclusions | Discussion conjointe avec l'équipe GC des résultats obtenus |

### 4. Contraintes techniques

- Langage principal : Python 3.9+;
- Reproductibilité : graine aléatoire fixée (random_state=42), fichier requirements.txt ou environment.yml fourni;
- Les décisions méthodologiques doivent être justifiées dans les cellules Markdown du notebook;
- L'interface doit être déployable localement, sous forme d'application web (Streamlit, Flask, Gradio, ...) ou d'application bureau (PyQt, Tkinter, ...).

## ANNEXE COMMUNE — Plan de collaboration & Rapport

### 1. Plan de collaboration GC / Info

Ce tableau définit pour chaque livrable : qui le produit, qui contribue, et qui valide.

| Tâche / Livrable | Responsable | Contributeur | Validé par |
|---|---|---|---|
| Lecture & présentation du dataset | GC | Info (questions) | Les deux |
| Rédaction descriptions textuelles | GC | — | Encadrant GC |
| Annotation Score_Risque | GC | — | Encadrant GC |
| Note Technique Métier + lexique + seuils | GC | — | Encadrant GC |
| Grille d'analyse des risques | GC | — | Encadrant GC |
| Installations sanitaires | GC | — | Encadrant GC |
| Prétraitement données numériques | Info | GC (seuils) | Encadrant Info |
| Prétraitement données textuelles / NLP | Info | GC (lexique) | Encadrant Info |
| Modèle ML / IA + évaluation | Info | — | Encadrant Info |
| Validation terrain des prédictions (.csv) | GC | Info (calcul) | Encadrant GC |
| Wireframe & indicateurs dashboard | GC | Info (faisabilité) | Les deux |
| Développement dashboard / interface web | Info | GC (contenu) | Les deux |
| Rapport — parties contexte & risques (1–2) | GC | — | Encadrant GC |
| Rapport — parties IA & résultats (3–4) | Info | — | Encadrant Info |
| Rapport — conclusion & interprétation | Les deux | — | Les deux |
| PPT slides 1–4 (contexte, risques) | GC | — | Les deux |
| PPT slides 5–9 (modèle, résultats) | Info | — | Les deux |
| Script narratif vidéo IA | GC | Info (prod.) | Les deux |

### 2. Structure attendue du rapport écrit

| Section du rapport | Responsable | Contenu attendu |
|---|---|---|
| Partie 1 — Contexte et présentation du chantier | GC | Description de l'ouvrage, contraintes terrain, enjeux sécurité (1–2 pages) |
| Partie 2 — Analyse des risques et Note Technique Métier | GC | Lexique de danger, seuils, grille d'analyse complète, hiérarchisation des 5 risques critiques, mesures préventives/correctives, installations sanitaires (4–6 pages) |
| Partie 3 — Méthodologie IA et résultats | Info | Prétraitement, choix d'architecture, entraînement, métriques comparatives, figures, explicabilité (4–6 pages) |
| Partie 4 — Dashboard et interface de déploiement | Info | Description de l'interface, captures d'écran, indicateurs affichés et leur justification terrain (1–2 pages) |
| Partie 5 — Interprétation conjointe et recommandations | GC + Info | Analyse des divergences modèle vs expertise GC, facteurs critiques identifiés, recommandations opérationnelles (2–3 pages) |